Data Mining

의사 결정 트리 과제



2021년 5월 20일

유방암 진단

의사 결정 트리로 유방암을 진단해보자.

kNN

accuracy: 0.956

precision: 0.97

recall: 0.746

fl_score : 0.843

로지스틱 회귀

accuracy: 0.965

precision: 1.0

recall: 0.901

fl_score: 0.948

의사 결정 트리

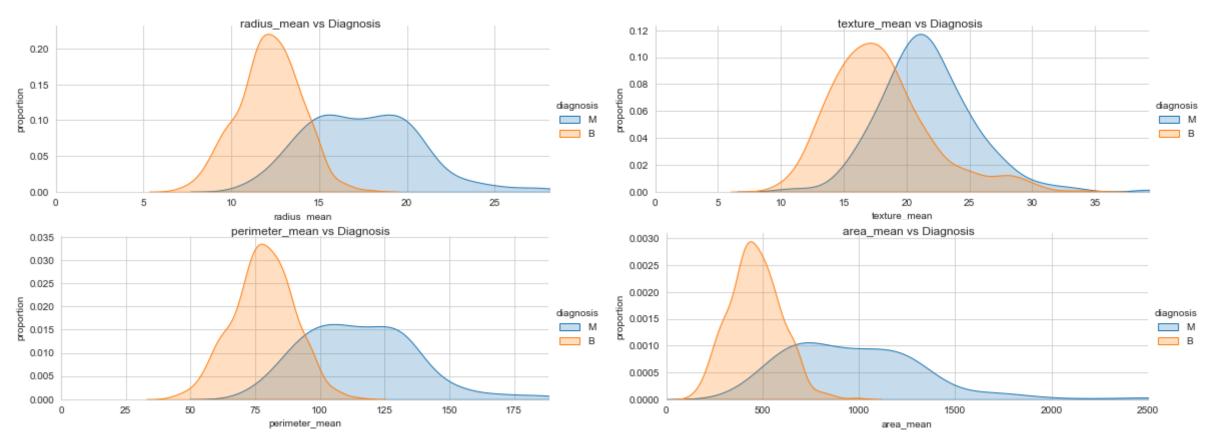
accuracy: 0.97

랜덤 포레스트

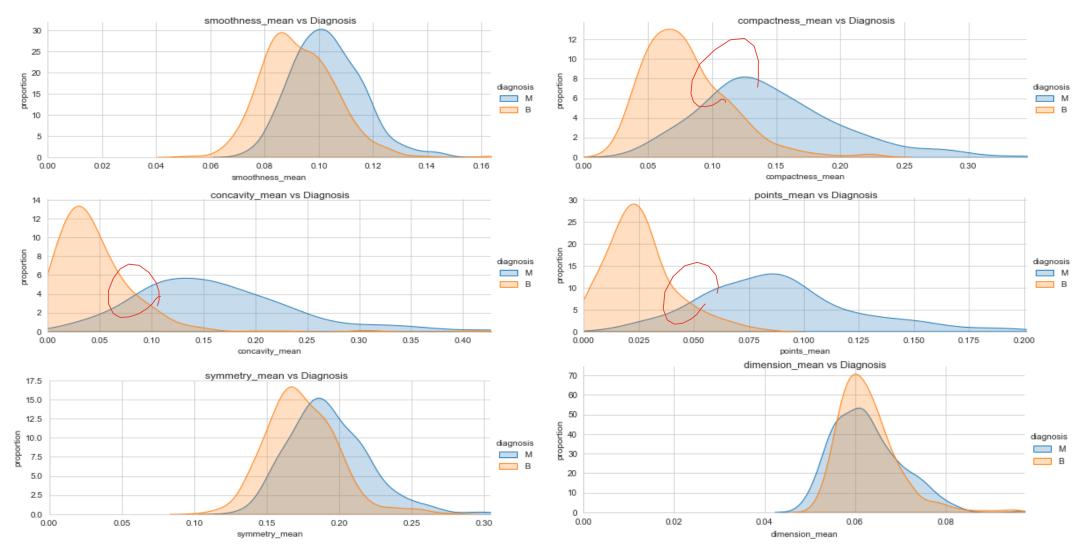


데이터 탐색 특징 별 분포

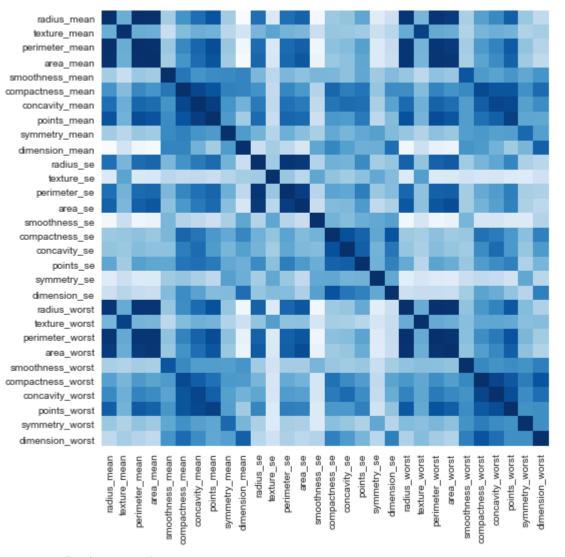




데이터탐색특징 별분포



특징 선택 및 추출 전체 특징



특징이 많아지면 상관성을 갖는 특징을 수작업으로 찾기가 어렵다.

© 2021 SeongJin Yoon. All Rights Reserved.

- 0.8

- 0.6

- 0.4

- 0.2

- 0.0

- -0.2

RFECV (Recursive Feature Elimination with Cross Validation)

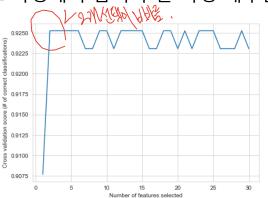
재귀적 특징 제거 방식

RFE (Recursive Feature Elimination) = 700 431

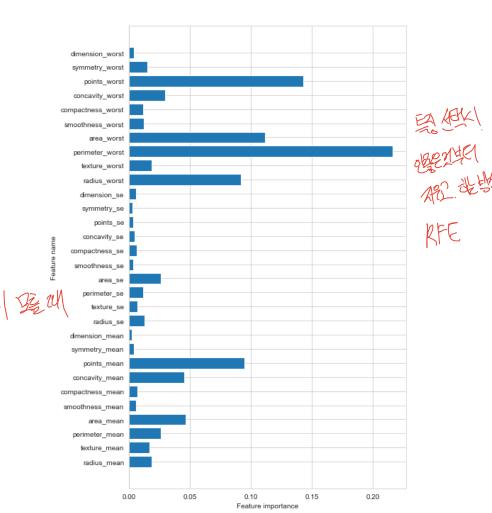
- 학습을 할 때 특징의 중요도를 계산해서 중요도가 낮은 순서로 특징을 제거하면서 원하는 개수가 될 때까지 반복하는 방식
- 단, 특징을 몇 개 남겨야 할지 지정해야 함

RFECV (Recursive Feature Elimination with Cross Validation)

RFE를 진행하면서 특징을 지울 때마다 모델의 성능을 교차 결정 방식으로 측정해서 남겨야 할 특징 개수를 정함 얼룩 선생님 보고 보다 되었다.







K-폴드 교차 검증 (K-fold Cross Validation)

데이터 분할에 따라 성능이 달라지므로 K번 훈련하고 검증해서 성능을 평균을 내는 방법



- 훈련 데이터를 K 등분
- · K-1개 폴드는 훈련에 사용하고 나머지 1개 폴드는 검증에 사용
- 검증 폴드를 한 칸씩 이동하면서 전체 K번 훈련과 검증을 실시
- 훈련 및 검증 성능은 K번 실행한 성능을 평균으로 사용

차원 축소 특징 선택

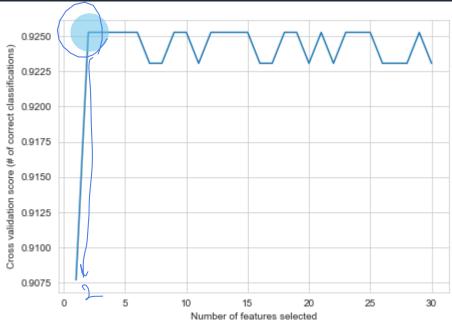
RFECV 실행

https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.RFECV.html

차원 축소 특징 선택

특징 선택을 위한 훈련 과정의 성능 그래프

```
# Plot number of features VS. cross-validation scores
plt.figure(figsize=(7,5))
plt.xlabel("Number of features selected")
plt.ylabel("Cross validation score (# of correct classifications)")
plt.plot(range(min_features_to_select, len(rfe.grid_scores_)+min_features_to_select),rfe.grid_scores_)
plt.show()
```



© 2021 SeongJin Yoon. All Rights Reserved.

9

차워 축소 특징선택

선택된 특징 확인

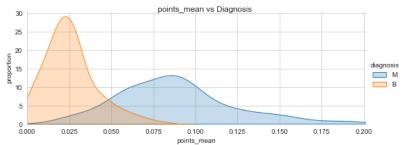
```
明显的 4年3月21日21日
best features = X train.columns.values[rfe.support]
drop features = [ column name for column name in column names[2:-
1] if column name not in best features ]
print('Optimal number of features :', rfe.n features )
print('Best features :', best features)
```

Optimal number of features : 2

Best features : ['points mean' 'perimeter worst']

print('Drop features :', drop features)

Drop features: ['radius_mean', 'texture_mean', 'perimeter_mean', 'area_mean', 'smoothness_mean', 'compactness_mean', 'concavity_mean', 'symmetry_mean', 'dimension_mean', 'radius_se', 'texture_se', 'perimeter_se', 'area_se', 'smoothness_se', 'compactness_se', 'concavity_se', 'points_se', 'symmetry_se', 'dimension_se', 'radius_worst', 'texture_worst', 'area_worst', 'smoothness_worst', 'compactness_worst', 'concavity_worst', 'points_worst', 'symmetry_worst', 'dimension_worst']

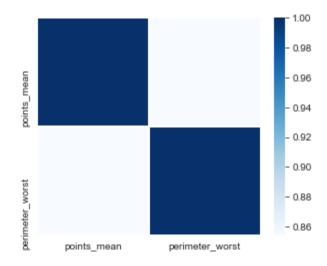




특징 선택 및 추출

특징 선택

'points_mean', 'perimeter_worst'



특징 추출

Logistic regression of 1/2/10/2/21 PCA로 11개의 특징을 추출

- 0.6 4 5 - 0.4 9 - 0.2 6 - 0.0 9 6

세 모델의 성능

최대 트리 깊이 = 3, 리프 노드 샘플 수 = 12

Accuracy of Decision Tree classifier on original training set: 0.96

Accuracy of Decision Tree classifier on original test set: 0.92

Accuracy of Decision Tree classifier on reduced training set: 0.95

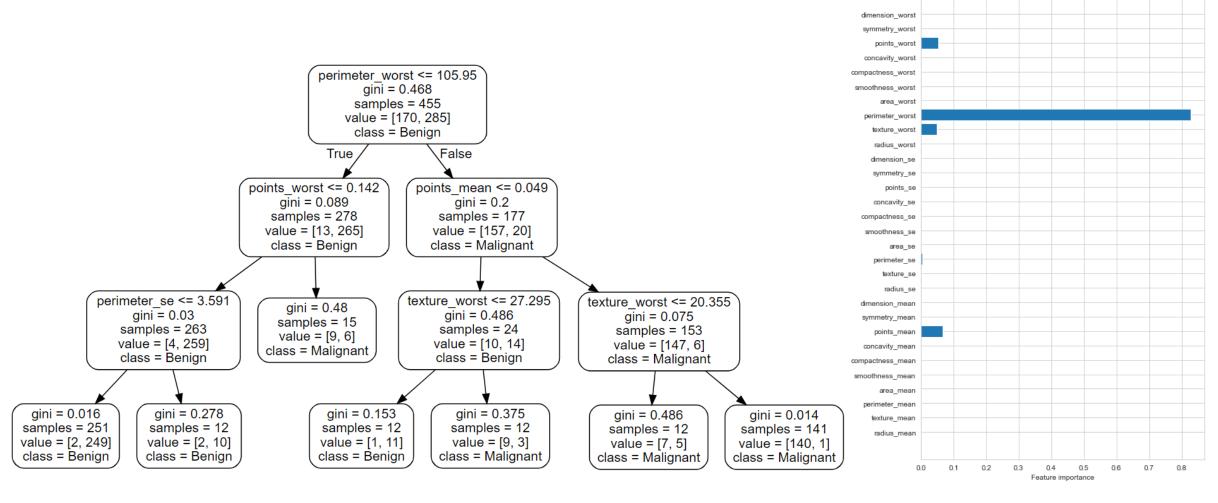
Accuracy of Decision Tree classifier on reduced test set: 0.90

Accuracy of Decision Tree classifier on PCA-transformed training set: 0.94

Accuracy of Decision Tree classifier on PCA-transformed test set: 0.92

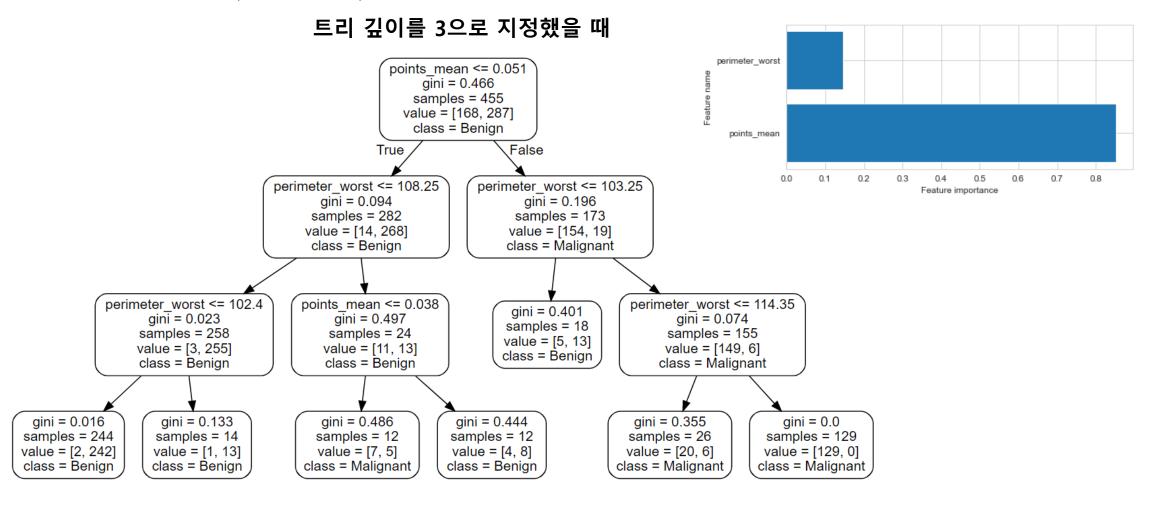
12

전체 특징



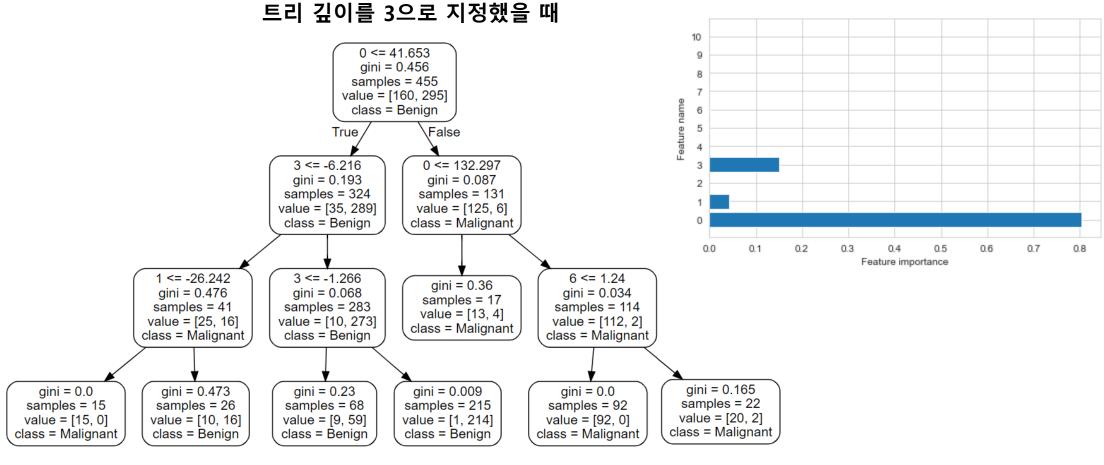
Accuracy of Decision Tree classifier on original training set: 0.96 Accuracy of Decision Tree classifier on original test set: 0.92

특징 선택 (RFECV)



Accuracy of Decision Tree classifier on reduced training set: 0.95 Accuracy of Decision Tree classifier on reduced test set: 0.90

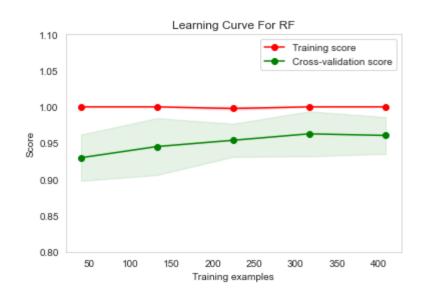
특징 추출 (PCA)

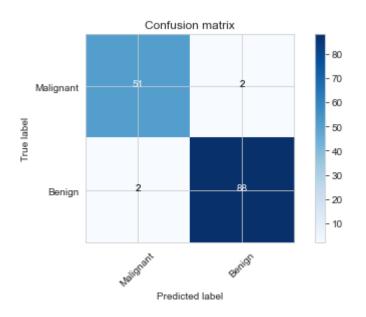


Accuracy of Decision Tree classifier on PCA-transformed training set: 0.94 Accuracy of Decision Tree classifier on PCA-transformed test set: 0.92

랜덤 포레스트

랜덤 포레스트를 적용하면 정확도가 97%까지 향상되는 것을 확인해보자.





Accuracy of Random Forest Classifier on training data: 1.00 Accuracy of Random Forest Classifier on testing data: 0.97

Thank you!

